Instituto Politécnico do Cávado e Ave

Escola Superior de Tecnologia

Licenciatura

em

Engenharia de Sistemas Informáticos

Unidade Curricular: Integração de Sistemas de Informação

Docente responsável: Óscar Ribeiro

Relatório do projeto

Nuno Miguel Rodrigues da Silva, a25417

Outubro de 2025

Índice

Índice de imagens 4
Siglas e Abreviaturas 5
1. Enquadramento 6
2. Problema 7
3. Estratégia utilizada 8
3.1 Principais operadores envolvidos 8
4. Transformações 9
4.2 Diagrama 9
4.3 Componente 1 - Input Data Source 10
JSON Reader + JSON Path + Ungroup 10
XML Reader + XPath (XML) 10
CSV Reader 10
4.3 Componente 2 – Data Integration e Aggregation 11
String to Date&Time 11
Date&Time to String 11
Number to String 11
String Manipulation (Regex) 11
Joiner 12
Rule Engine (exemplos) 12
GroupBy 13
Sorter 13
Row Filter 13
4.4 Componente 3 – Output & Visualization 14
Bar Chart 14
Scatter Plot 14
CSV Writer 14
Excel Writer 14

DB Writer 15
SQLite Connector 15
Java Snippet 15
5. Jobs 16
5.1 Diagramas 16
5.2 Explicação 17
Input 17
Transformações 17
Análise/Estatística + Saída/Visualização 17
5.3 Resultados 18
6. Vídeo com demonstração 19
7. Conclusão e trabalhos futuros 20
7.1 Conclusão 20
7.2 Trabalhos futuros 20
8. Referências 21

Índice de imagens

Figura 1 - Transformações Knime 9
Figura 2 - Normalização do tipo de ocorrência 11
Figura 3 - Normalização de datas 11
Figura 4 - Normalização de estados da viatura 12
Figura 5 - Classificação do tempo de resposta 12
Figura 6 - Classificação da temperatura 12
Figura 7 - Atribuição de veículos por categoria de ocorrência 12
Figura 8 - Java (código utilizado) 15
Figura 9 - Jobs do Knime 16
Figura 10 - Jobs subdivididos 16
Figura 11 - Bar Char (Tempo médio de resposta face condições meteorológicas) 18
Figura 12 - Scatter Plot (Lista de Veículos com estado ativo) 18
Figura 13 - Ficheiro data base 18
Figura 14 - Código QR do vídeo 19

Siglas e Abreviaturas

- ✓ **ANEPC –** Autoridade Nacional de Emergência e Proteção Civil, site do governo que contém em tempo real, todas as ocorrências ativas no país.

- ✓ **CSV –** Comma-Separated Values, formato de ficheiro de texto estruturado, em que os valores são separados por vírgulas;

- ✓ **DB –** DataBase, Base de dados onde os dados podem ser armazenados e consultados;

- ✓ **ETL –** Extract, Transform, Load, processo de extração, transformação e carregamento de dados;

- ✓ **JSON –** JavaScript Object Notation, formato leve de troca de dados, baseado em texto e estruturado em pares chave-valor;

- ✓ **QR –** Quick Response (Code), código bidimensional que pode ser lido por dispositivos móveis, usado aqui para aceder ao vídeo demonstrativo;

- ✓ **SQL –** Structured Query Language, linguagem padrão para manipulação e consulta de dados em bases de dados relacionais;

- ✓ **XML –** eXtensible Markup Language, linguagem de marcação extensível usada para estruturar e transportar dados.

1. Enquadramento

O presente documento constitui o relatório do primeiro trabalho prático da unidade curricular de Integração de Sistemas de Informação, lecionada pelo docente, Óscar Ribeiro.

Assim sendo, o presente trabalho tem como objetivo implementar um processo ETL (Extract, Transform, Load) utilizando a ferramenta KNIME, integrando dados provenientes de diferentes fontes e formatos (CSV, JSON e XML).

Neste projeto, utilizou-se dados simulados de ocorrências dos bombeiros (ficheiro CSV) e com informação meteorológica (ficheiro JSON) e ainda uma lista de veículos (ficheiro XML), representando um cenário realista de integração de fontes distintas. O objetivo consistiu em cruzar e analisar a informação, permitindo perceber, por exemplo, como fatores meteorológicos (temperatura, vento, precipitação) podem influenciar o tempo de resposta operacional dos bombeiros em diferentes tipos de ocorrência e quais/quantos tipos de meios/veículos existentes e de certa forma disponíveis para atuarem nas mais diversas ocorrências (acidente rodoviário, incêndio urbano, incêndio florestal, resgate e emergência médica).

Além da simples integração, o trabalho pretendeu ainda demonstrar:

- ✓ A utilização de operações de transformação como normalização, conversão de tipos de dados, e categorização;
- ✓ A criação de logs e mecanismos de controlo, que registam a execução do workflow.
- ✓ A exportação dos resultados não apenas para ficheiros (CSV e Excel), mas também para uma base de dados SQLite, simulando um cenário de armazenamento centralizado base de dados SQLite;
- ✓ A construção de visualizações gráficas que permitem interpretar os resultados de forma clara e intuitiva.

Desta forma, o projeto enquadra-se no contexto pedagógico de consolidação de conhecimentos sobre integração de sistemas, ao mesmo tempo que simula um cenário aplicado ao mundo real, onde diferentes fontes de dados devem ser integradas para apoiar a análise e a tomada de decisão.

2. Problema

O problema proposto neste trabalho consiste em demonstrar, através de um processo de ETL, a integração de dados provenientes de diferentes fontes e formatos, transformando-os e analisando-os de forma a retirar conhecimento útil.

Foi definido um cenário de estudo, no qual é real e o mesmo é relacionado com ocorrências registadas pelos bombeiros. Todas as ocorrências incluem informação como a data, o local, o tipo de ocorrência (ex.: incêndio urbano, incêndio florestal, resgate, emergência médica), e o tempo de resposta operacional. Estes dados encontram-se inicialmente num ficheiro CSV.

Ao mesmo tempo, foram utilizados dados meteorológicos fictícios, que são assim uma fonte complementar de informação. Estes dados estão presentes num ficheiro JSON. Através deste ficheiro, é possível recolher variáveis como temperatura, vento e precipitação, que podem ter impacto direto no tempo de resposta e nas condições de atuação das equipas de bombeiros.

Num outro ficheiro, em formato XML, é constituído uma lista de veículos, com dados como a matrícula, sigla, data, marca, capacidade e estado.

O desafio principal é, portanto, conseguir integrar estes dados (CSV, JSON e XML), corrigi-los /aperfeiçoar e exportá-los para análise, aplicando transformações que incluem:

- ✓ Conversão de tipos de dados;
- ✓ Normalização de valores textuais;
- ✓ Categorização de ocorrências;
- ✓ Cálculo de estatísticas como médias, mínimos e máximos;
- ✓ Filtrações de variáveis entre outros.

Logo após a fase de extração e transformação, os dados serão carregados em ficheiros CSV/Excel e uma base de dados SQLite, permitindo tanto a persistência como a consulta estruturada dos resultados. No final, pretende-se não apenas validar a correta execução do processo de ETL, mas também gerar visualizações que facilitem a interpretação da informação.

3. Estratégia utilizada

A estratégia seguida baseou-se em três etapas principais:

- ✓ **Extração:** Importação de ficheiros em formatos distintos (CSV, JSON e XML);
- ✓ **Transformação:** Normalização, conversão de tipos, categorização, tratamento e junção de tabelas;
- ✓ **Carregamento**: Exportação de resultados para ficheiros (CSV e Excel) e para uma base de dados SQLite.

3.1 Principais operadores envolvidos

- ✓ CSV Reader, JSON Reader, XML Reader;
- ✓ String Manipulation, Rule Engine;
- ✓ Joiner, GroupBy, Row Filter;
- ✓ Java Snippet (logs);
- ✓ DB Writer (SQLite);
- ✓ CSV Writer, Excel Writer;
- ✓ Gráficos (Bar Chart, Scatter Plot);
- ✓ Ungroup, Sorter.

4. Transformações

O processo de transformação foi dividido em três componentes principais que implementam as fases do modelo ETL (*Extract, Transform, Load*). Dentro de cada componente foram aplicadas operações de leitura, normalização, integração e visualização, de forma a preparar e analisar os dados de ocorrências dos bombeiros e condições meteorológicas.

4.2 Diagrama

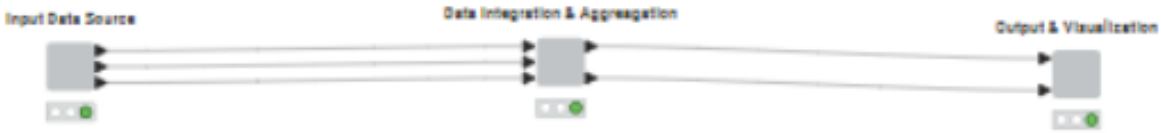


Figura 1 - Transformações Knime

4.3 Componente 1 - Input Data Source

JSON Reader + JSON Path + Ungroup

- ✓ **Objetivo:** extrair campos do JSON e “achatar” listas para tabela;
- ✓ **Configuração:** paths para Data, Local, Tipo, Temperatura, Vento, Precipitação; definir tipos (String/Double);
- ✓ **Justificação:** transformar dados semi-estruturados em tabela utilizável no join.

XML Reader + XPath (XML)

- ✓ **Objetivo:** extrair campos equivalentes do XML (ex.:Id, Sigla, Data, Matrícula, Marca, Capacidade e Estado);
- ✓ **Configuração:** expressões XPath para cada elemento; mapear para colunas;
- ✓ **Justificação:** demonstra manipulação de outro formato (XML) e prepara dados para integração/validação.

CSV Reader

- ✓ **Objetivo:** extrair campos equivalentes do CSV;
- ✓ **Configuração:** expressões CSV para cada elemento;
- ✓ **Justificação:** demonstra manipulação de outro formato (CSV) e prepara dados para integração/validação.

4.3 Componente 2 – Data Integration e Aggregation

String to Date&Time

- ✓ **Objetivo:** converter Data (String) para tipo data;
- ✓ **Configuração:** formato de entrada;
- ✓ **Justificação:** garante joins corretos, ordenações e estatísticas temporais.

Date&Time to String

- ✓ **Objetivo:** converter novamente a coluna Data para String após o processamento;
- ✓ **Configuração:** escolher o formato de saída normalizado;
- ✓ **Justificação:** uniformiza o formato textual da data para facilitar joins com outras fontes em texto e assegurar compatibilidade na exportação.

Number to String

- ✓ **Objetivo:** tornar Vento, Precipitação, numéricos;
- ✓ **Configuração:** Vento → Integer, Precipitação → Double, Replace selected columns;
- ✓ **Justificação:** necessário para médias (GroupBy) e gráficos.

String Manipulation (Regex)

- ✓ **Objetivo:** normalizar tipo e corrigir variações de escrita (acentos/maiúsculas).
- ✓ **Configuração (exemplos):**

```
regexReplace(
  regexReplace(
    regexReplace(
      regexReplace($Tipo$, "(?i).*incendio.*florestal.*", "Incêndio Florestal"),
      "(?i).*incendio.*urbano.*", "Incêndio Urbano"
    ),
    "(?i).*emergencia.*medica.*", "Emergência Médica"
  ),
  "(?i).*acidente.*", "Acidente Rodoviário"
)
```

Figura 2 - Normalização do tipo de ocorrência

```
regexReplace($Data$, "(\\d{4})-(\\d{2})-(\\d{2})", "$3/$2/$1")
```

Figura 3 - Normalização de datas

```
regexReplace(
    regexReplace($Estado$, "(?i).*manuten[cç][aã]o.*", "Em Manutenção"),
    "(?i)^\\s*(at(v)?|ativ[o]?|activo?|a|ok|atibo)\\s*$",
    "Ativo"
)
```

Figura 4 - Normalização de estados da viatura

- ✓ **Justificação:** evita categorias duplicadas e palavras mal formatadas; aumenta qualidade da agregação.

Joiner

- ✓ **Objetivo:** integrar CSV (ocorrências) + meteo (JSON/XML);
- ✓ **Configuração:** chaves Data + Local; tipo de join Inner;
- ✓ **Justificação:** consolida fontes heterogéneas para análise conjunta.

Rule Engine (exemplos)

- ✓ **Objetivo:** criar faixas analíticas;
- ✓ **Configuração (exemplos):**

```
$TempoResposta_min$ <= 10 => "Muito Rápido"
$TempoResposta_min$ <= 20 => "Rápido"
$TempoResposta_min$ <= 40 => "Moderado"
TRUE => "Demorado"
```

Figura 5 - Classificação do tempo de resposta

```
$Temperatura$ <= 24 => "Frio"
$Temperatura$ <= 27 => "Ameno"
$Temperatura$ <= 32 => "Quente"
TRUE => "Muito Quente"
```

Figura 6 - Classificação da temperatura

```
$Sigla$ MATCHES "(?i)VAOP-.*" => "Acidente Rodoviário"
$Sigla$ MATCHES "(?i)VTTR-.*" => "Incêndio Florestal"
$Sigla$ MATCHES "(?i)VFCI-.*" => "Incêndio Florestal"
$Sigla$ MATCHES "(?i)VLCI-(?!01).*" => "Incêndio Florestal"
$Sigla$ MATCHES "(?i)(VTTU-.*|VSAE-.*|VECI.*|VALE-.*)" => "Incêndio Urbano"
$Sigla$ MATCHES "(?i)(MOTO-.*|VOPE-.*)" => "Resgate"
TRUE => "Outra"
```

Figura 7 - Atribuição de veículos por categoria de ocorrência

- ✓ **Justificação:** facilita leitura e análise comparativa nos gráficos.

GroupBy

- ✓ **Objetivo:** calcular estatísticas por Tipo (1º Group By) e Trabalho (2º Group By);
- ✓ **Configuração:** Group 1 = Tipo; Aggregations = Mean(TempoResposta_min), Mean(Temperatura), Mean(Precipitação), Mean(Vento);

  Group 2 = Trabalho; Aggregations = Sigla;

- ✓ **Justificação:** sumariza dados em indicadores.

Sorter

- ✓ **Objetivo:** ordenar os registos de acordo com uma coluna (ex.: Trabalho);
- ✓ **Configuração:** escolher a coluna a ordenar;
- ✓ **Justificação:** garante uma sequência organizada dos dados.

Row Filter

- ✓ **Objetivo:** selecionar apenas linhas que respeitam uma determinada condição, neste caso, filtrar veículos que apresentem estado = Ativo;
- ✓ **Configuração:** definir a coluna de filtragem e os valores ou intervalos aceites;
- ✓ **Justificação:** permite isolar subconjuntos relevantes dos dados, removendo os desnecessários.

4.4 Componente 3 – Output & Visualization

Bar Chart

- ✓ **Objetivo:** representar graficamente o tempo médio de resposta por tipo de ocorrência, permitindo uma comparação visual entre categorias (ex.: incêndios, emergências médicas, acidentes rodoviários);
- ✓ **Configuração:** definir a coluna de categorias no eixo X (Tipo de Ocorrência) e a coluna de valores numéricos no eixo Y (Média do TempoResposta_min);
- ✓ **Justificação:** facilita a análise de padrões e tendências, permitindo identificar rapidamente quais os tipos de ocorrências que exigem maior tempo de resposta.

Scatter Plot

- ✓ **Objetivo:** analisar a relação entre variáveis numéricas, veículos ativos;
- ✓ **Configuração:** selecionar a Aplicação do Veículos como eixo X e Veículos Ativos como eixo Y;
- ✓ **Justificação:** ajuda a perceber se quais veículos estão ativos, e que podem ser integrados nos vários tipos de urgência.

CSV Writer

- **Objetivo:** exportar os resultados processados para um ficheiro CSV;
- **Configuração:** indicar o caminho de destino e escolher se quer substituir ou acrescentar ao ficheiro existente;
- **Justificação:** permite guardar os dados tratados em formato padrão e reutilizável em relatórios, partilhas ou análises futuras.

Excel Writer

- ✓ **Objetivo:** exportar os resultados agregados para um ficheiro Excel, facilitando o tratamento adicional;
- ✓ **Configuração:** definir o nome da folha (sheet), caminho do ficheiro e formato de escrita (substituir ou adicionar);
- ✓ **Justificação:** assegura acessibilidade dos dados a utilizadores não técnicos, ampliando a utilidade prática do projeto.

DB Writer

- ✓ **Objetivo:** armazenar os resultados finais numa base de dados SQLite, garantindo persistência e possibilidade de futuras consultas;
- ✓ **Configuração:** ligação ao SQLite Connector, nome da tabela e modo de escrita (por exemplo, “Remove and Create” para sobrescrever dados antigos);
- ✓ **Justificação:** possibilita a integração dos resultados num sistema de gestão de bases de dados, tornando o processo escalável e auditável.

SQLite Connector

- ✓ **Objetivo:** estabelecer ligação entre o KNIME e a base de dados SQLite, permitindo ler ou gravar dados diretamente;
- ✓ **Configuração:** indicar o caminho do ficheiro da base de dados .db e o modo de ligação (criar ou usar existente);
- ✓ **Justificação:** assegura comunicação entre o workflow e a base de dados local, essencial para guardar os resultados de forma persistente e estruturada.

Java Snippet

- ✓ **Objetivo:** gerar logs automáticos de execução, neste caso, data/hora de processamento;
- ✓ **Configuração:** inserir código Java personalizado para criar colunas com mensagens de log ou eventos relevantes;
- ✓ **Justificação:** adiciona rastreabilidade ao processo, permitindo validar execuções e garantir a integridade das operações de saída.

```
out_DataExecucao = java.time.LocalDateTime.now()
        .format(java.time.format.DateTimeFormatter.ofPattern("yyyy-MM-dd HH:mm:ss"));
```

Figura 8 - Java (código utilizado)

5. Jobs

O workflow foi estruturado em três Jobs principais, correspondentes aos componentes definidos anteriormente, que se executam sequencialmente para implementar o processo ETL completo.

Cada Job possui entradas e saídas definidas, assegurando modularidade e reusabilidade do processo.

5.1 Diagramas

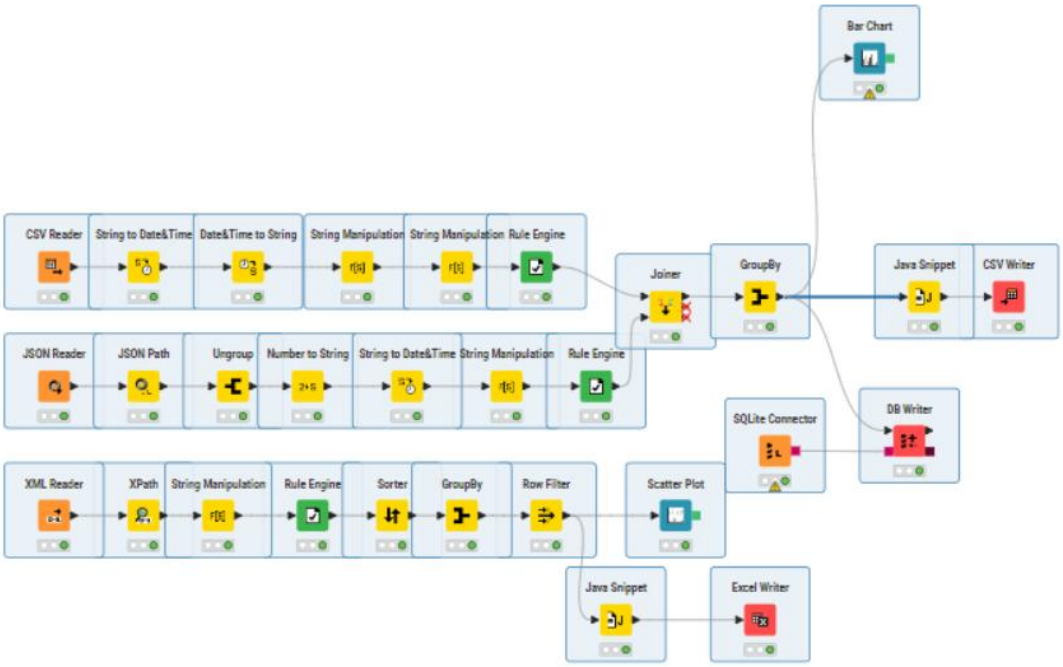


Figura 9 - Jobs do Knime

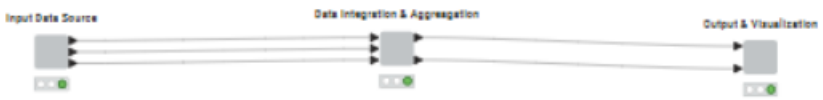


Figura 10 - Jobs subdivididos

5.2 Explicação

Input

- ✓ **Contém:** CSV Reader, JSON Reader (+ JSON Path + Ungroup), XML Reader (+ XPath);
- ✓ **Serve para:** Responsável pela leitura e extração de dados. Ao ser executado, importa ficheiros CSV, JSON e XML, converte e prepara a informação para integração. A saída contém dados já normalizados e prontos para transformação.

Transformações

- ✓ **Contém:** String to Date&Time, String to Number, String Manipulation (Regex), Rule Engine, Date&Time to String, Row Filter e Sorter, Group By, Number to String e Joiner;
- ✓ **Serve para:** Este job processa os dados de entrada, aplicando regras, regex e operações de integração. Produz um dataset agregado com médias, classificações e correções. Representa o núcleo lógico do workflow.

Análise/Estatística + Saída/Visualização

- ✓ **Contém:** Bar Chart (Tempo médio), Scatter Plot (Trabalho × Sigla), CSV/Excel Writer, SQLite Connector + DB Writer e Java Snippet;
- ✓ **Serve para:** comunicar resultados (gráficos) e persistir em ficheiros e base de dados (SQLite).

5.3 Resultados

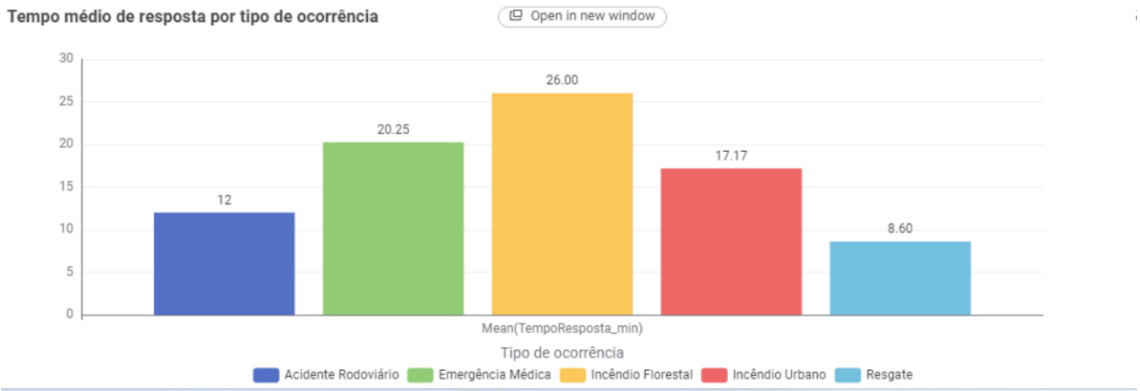


Figura 11 - Bar Char (Tempo médio de resposta face condições meteorológicas)

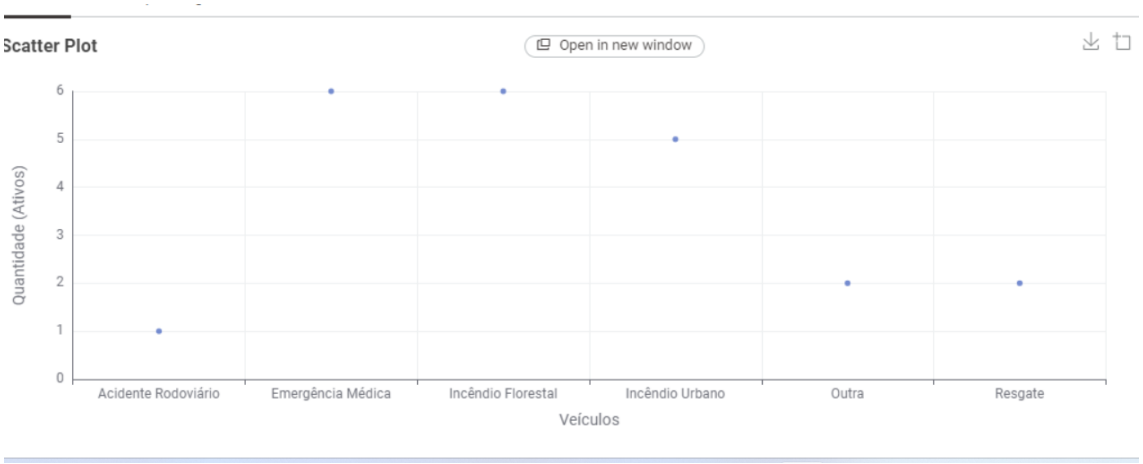


Figura 12 - Scatter Plot (Lista de Veículos com estado ativo)



Figura 13 - Ficheiro data base

6. Vídeo com demonstração



Figura 14 - Código QR do vídeo

Link, caso não dê: https://youtu.be/Xo4Ld-MLddY

7. Conclusão e trabalhos futuros

7.1 Conclusão

Ao longo deste trabalho foi possível desenvolver um processo ETL (Extract, Transform, Load) completo no KNIME, utilizando dados de diferentes formatos (CSV, JSON e XML) e aplicando diversas operações de transformação, integração e análise. Foram implementados:

- ✓ **Extração** de dados de várias fontes e formatos.
- ✓ **Transformações** como conversão de tipos, normalização textual com expressões regulares e categorização de valores;
- ✓ **Integração** de dados através do Joiner, consolidando ocorrências e dados meteorológicos;
- ✓ **Agregações** e estatísticas com GroupBy, permitindo calcular médias e indicadores relevantes;
- ✓ **Carregamento** dos resultados tanto em ficheiros (CSV/Excel) como numa base de dados SQLite;
- ✓ **Visualizações** (gráficos de barras, dispersão) que facilitam a interpretação dos resultados;
- ✓ **Logs de execução** para controlo do processo;
- ✓ **Filtração** e **ordenação** de dados.

7.2 Trabalhos futuros

Apesar dos resultados obtidos, existem melhorias que poderiam ser implementadas:

- ✓ **Integração com APIs externas** – por exemplo, importar dados meteorológicos em tempo real através de um serviço web ou ocorrências reais, extraídas da ANEPC;
- ✓ **Dashboard interativo** – exportar os resultados para ferramentas como Power BI ou Grafana para criar relatórios mais dinâmicos;
- ✓ **Escalabilidade** – adaptar o processo a bases de dados maiores ou a sistemas distribuídos.

8. Referências

- ✓ Material da unidade curricular;
- ✓ Documentação oficial KNIME: https://www.knime.com/documentation;
- ✓ ChatGPT;